

Analisis Big Data Lowongan Kerja Indonesia Menggunakan Apache Spark SQL dan Algoritma K-Means pada Spark MLlib

Analitik Big Data

Disusun oleh:
Reyno Benedict
NIM: 235150207111048

Dosen Pengampu : Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.



PROGRAM STUDI TEKNIK INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS BRAWIJAYA
MALANG
TAHUN 2026

Bab I Pendahuluan

1.1 Latar Belakang

Perkembangan platform rekrutmen *online* menghasilkan data lowongan kerja dalam jumlah besar yang terus bertambah setiap hari. Data tersebut memuat berbagai informasi penting seperti posisi pekerjaan, lokasi, perusahaan, tingkat pendidikan, pengalaman kerja, dan rentang gaji. Informasi ini dapat dimanfaatkan untuk memahami kondisi dan tren pasar kerja secara lebih objektif berdasarkan data aktual.

Pada proyek ini dilakukan pengumpulan data lowongan kerja dari platform glints.com menggunakan teknik *web scraping*. Data yang diperoleh kemudian dibersihkan dan dianalisis menggunakan Apache Spark SQL untuk menghasilkan berbagai informasi seperti distribusi lokasi pekerjaan, kebutuhan pendidikan, rentang gaji, serta perusahaan yang paling aktif membuka lowongan.

Selain analisis deskriptif, proyek ini juga menerapkan algoritma *K-Means* menggunakan Spark MLlib untuk mengelompokkan karakteristik lowongan kerja berdasarkan atribut yang tersedia. Hasil analisis dan visualisasi yang dihasilkan diharapkan dapat memberikan gambaran umum mengenai kondisi pasar kerja di Indonesia sekaligus menunjukkan penerapan teknologi *Big Data* menggunakan Apache Spark.

1.2 Rumusan Masalah

1. Bagaimana mengumpulkan data lowongan kerja dari Glints.com menggunakan *web scraping*?
2. Bagaimana melakukan analisis data lowongan kerja menggunakan *Apache Spark SQL*?
3. Bagaimana mengelompokkan data lowongan kerja menggunakan algoritma *K-Means* dan menyajikan hasilnya dalam bentuk visualisasi?

1.3 Tujuan Proyek

1. Mengumpulkan dan membersihkan data lowongan kerja dari Glints.com.
2. Melakukan analisis data menggunakan Apache Spark SQL untuk memperoleh informasi pasar kerja.
3. Mengimplementasikan *K-Means* pada Spark MLlib serta menyajikan hasil analisis dalam bentuk visualisasi.

1.4 Manfaat Proyek

1. Memberikan gambaran mengenai tren dan karakteristik pasar kerja berdasarkan data lowongan kerja aktual.
2. Menunjukkan penerapan Apache Spark SQL dan Spark MLlib dalam pengolahan data skala besar.
3. Menjadi contoh implementasi analisis *Big Data* pada data lowongan kerja.

Bab II Metodologi dan Implementasi

2.1 Pengumpulan data

Data diperoleh dari platform lowongan kerja Glints Indonesia menggunakan teknik *web scraping* berbasis Python dan Selenium. Informasi yang dikumpulkan meliputi judul pekerjaan, perusahaan, lokasi, jenis pekerjaan, rentang gaji, pendidikan, pengalaman kerja, serta deskripsi lowongan. Hasil *scraping* disimpan dalam format CSV dan menghasilkan sebanyak 1.133 data lowongan kerja yang digunakan pada proses analisis.

2.2 Pembersihan dan Persiapan Data

Dataset yang diperoleh kemudian melalui proses *data cleaning* untuk meningkatkan kualitas data. Tahapan yang dilakukan meliputi penghapusan data duplikat, penanganan nilai kosong, standarisasi format teks, serta konversi atribut gaji ke format numerik. Setelah proses pembersihan selesai, data disiapkan untuk kebutuhan analisis menggunakan Apache Spark.

2.3 Analisis Data dengan Apache Spark SQL

Data yang telah dibersihkan dimuat ke dalam *Spark DataFrame* dan dianalisis menggunakan *Spark SQL*. Analisis yang dilakukan meliputi:

1. Distribusi lowongan berdasarkan lokasi.
2. Distribusi jenis pekerjaan.
3. Analisis pendidikan dan pengalaman kerja.
4. Analisis rentang gaji.
5. Perusahaan dan posisi pekerjaan yang paling banyak tersedia.

Hasil analisis kemudian divisualisasikan menggunakan berbagai grafik untuk mempermudah interpretasi data.

2.4 Clustering Menggunakan SparkMLlib

Selain analisis deskriptif, proyek ini juga menerapkan teknik *machine learning* menggunakan Spark MLlib dengan algoritma *K-Means Clustering*. Tujuannya adalah mengelompokkan lowongan kerja berdasarkan kemiripan karakteristik yang dimiliki.

Tahap *clustering* diawali dengan proses *preprocessing* teks menggunakan *tokenization*, *StopWordsRemover*, *HashingTF*, dan *TF-IDF*. Selanjutnya dilakukan pengujian beberapa nilai *cluster* dan diperoleh model terbaik pada nilai $k = 3$ dengan *Silhouette Score* sebesar 0,0351.

2.5 Alur Proyek

Tahapan pengerjaan proyek dapat diringkas sebagai berikut:


1. Pengumpulan data lowongan kerja dari *Glints Indonesia*.
2. Pembersihan dan transformasi data.

3. Analisis data menggunakan Apache Spark SQL.
4. Visualisasi hasil analisis.
5. Penerapan *K-Means Clustering* menggunakan Spark MLlib.
6. Evaluasi hasil *clustering* menggunakan *Silhouette Score*.
7. Penyusunan laporan dan interpretasi hasil analisis.

BAB III Hasil dan Pembahasan

3.1 Hasil Pengumpulan Data

Data lowongan kerja pada penelitian ini diperoleh dari platform Glints Indonesia menggunakan teknik *web scraping*. Proses pengambilan data dilakukan secara otomatis menggunakan Selenium untuk mengakses halaman lowongan kerja yang bersifat dinamis serta BeautifulSoup untuk melakukan ekstraksi informasi dari setiap kartu lowongan yang ditampilkan. Pengumpulan data dilakukan menggunakan beberapa kata kunci yang mewakili bidang teknologi informasi, data, bisnis, desain, dan operasional sehingga cakupan data yang diperoleh menjadi lebih beragam. Informasi yang berhasil dikumpulkan meliputi judul pekerjaan, nama perusahaan, lokasi, rentang gaji, jenis pekerjaan, pengalaman kerja, tingkat pendidikan, persyaratan pekerjaan, tanggal publikasi, dan sumber platform.



The screenshot displays a CSV file named 'glints_jobs.csv' within a code editor. The file contains 23 rows of job data. The columns are labeled as follows: C1 (job_title), C2 (company_name), C3 (salary_ra), C4 (location), C5 (job_t), C6 (experie), C7 (educati), C8 (job_requir), C9 (posted_date), and C10 (source_platform). The data includes various job titles such as 'Software Engineer', 'Senior Software Engineer', and 'Junior Software Engineer', along with company names like 'Surya Maraya', 'PT. Meteor I', and 'PT. MUAT LOG'. The salary ranges, locations, and job types are also listed for each entry.

	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10
1	job_title	company_name	salary_ra	location	job_t	experie	educati	job_requir	posted_date	source_platform
2	C++ Software Engineer	Surya Maraya	Gaji Tida	Kab. Bu	Penuh	1-3 tah	Minimal	+2 C++	UrgentKemar	glints
3	Software Engineer	PT. Meteor I	Rp 7NBSPjt	Kab. Ta	Kontrak	3-5 tah	Minimal	+5 Remot	13 jam yang	glints
4	Software Engineer	PT. MUAT LOG	Rp 5NBSPjt	Jakarta	Penuh	1-3 tah	Minimal	+4 Softw	10 jam yang	glints
5	Software Engineer	Aldmic CODPM	Rp 7NBSPjt	Jakarta	Penuh	3-5 tah	Minimal	JavaScript	12 jam yang	glints
6	Software Engineer	BSG Group	Gaji Tida	Tangera	Penuh	1-3 tah	Minimal	+6 React	3 hari yang	glints
7	Software Engineer	PT Golden Te	Rp 3,2NBSP	Kab. Ke	Penuh	1-3 tah	Minimal	SQL +12	8 hari yang	glints
8	Software Engineer	PT Inter Sis	Gaji Tida	Jakarta	Penuh	1-3 tah	Minimal	+3 Larav	14 hari yan	glints
9	Software Engineer	PT Prima Vis	Gaji Tida	Jakarta	Penuh	Not Spe	Minimal	Teamwork	17 hari yan	glints
10	Software Engineer	Majoo Indone	Gaji Tida	Malang	Penuh	1-3 tah	Minimal	+2 Softw	18 hari yan	glints
11	Software Engineer	Dulain Group	Rp 4NBSPjt	Bandung	Penuh	1-3 tah	Minimal	+5 React	12 jam yang	glints
12	Software Engineer	Selaras Asia	Rp 5NBSPjt	Yogyakarta	Penuh	3-5 tah	Minimal	+2 SQL	7 hari yang	glints
13	Software Engineer	PT Teknolog	Rp 6,0NBSP	Jakarta	Penuh	1-3 tah	Minimal	+6 Node	13 hari yan	glints
14	Software Engineer (Golan	Pt. Solusi P	Rp 10NBSPjt	Tangera	Penuh	3-5 tah	Minimal	Hybrid +9	4 hari yang	glints
15	Senior Software Engineer	otaoku	Rp 8NBSPjt	Jakarta	Penuh	3-5 tah	Minimal	Mentoring	8 hari yang	glints
16	Software Engineer (Fulls	PT Reka Mult	Rp 4NBSPjt	Jakarta	Penuh	1-3 tah	Minimal	+16 SQL	9 hari yang	glints
17	Software Engineer Intern	Dulain Group	Rp 1,5NBSP	Bandung	Magang	1-3 tah	Minimal	PostgreSQL	10 jam yang	glints
18	Senior Software Engineer	Darawan Ary	Rp 13NBSPjt	Jakarta	Penuh	5-10 ta	Minimal	+2 Go /	Kemarin	glints
19	Senior Software Engineer	PT Teknolog	Rp 15NBSPjt	Jakarta	Penuh	5-10 ta	Minimal	+2 Agile	2 hari yang	glints
20	Junior Software Engineer	PT Mitra Man	Rp 4NBSPjt	Jakarta	Penuh	1-3 tah	Minimal	+4 Java	3 hari yang	glints
21	ROS Software Engineer	PT Widya Ino	Rp 4NBSPjt	Kab. SL	Penuh	1-3 tah	Minimal	+6 Ros S	6 hari yang	glints
22	Junior Software Engineer	Hijrahfood G	Rp 5NBSPjt	Bekasi	Penuh	1-3 tah	Minimal	+3 GIT	14 hari yan	glints
23	Software Engineer Intern	Algo bash	Rp 3NBSPjt	Jakarta	Magang	Not Spe	Minimal	+4 TypeS	15 hari yan	glints

Gambar 3.1 Raw Data hasil Scraping glints.com

Gambar 3.1 menunjukkan contoh data mentah (*raw data*) hasil proses *web scraping* yang disimpan ke dalam berkas CSV. Sebelum digunakan untuk analisis, data tersebut masih memerlukan tahap pembersihan data (*data cleaning*) untuk menghilangkan data duplikat, menangani nilai kosong, melakukan standarisasi format, serta mengekstraksi atribut yang diperlukan untuk proses analisis menggunakan Apache Spark SQL dan Spark MLlib. Dari proses pengumpulan data berhasil diperoleh sebanyak 1.133 lowongan kerja unik yang kemudian digunakan sebagai dataset penelitian.

3.2 Hasil Pembersihan dan Persiapan Data

Setelah proses *web scraping* selesai dilakukan, data mentah yang diperoleh masih memerlukan tahap pembersihan dan persiapan data sebelum dapat dianalisis menggunakan Apache Spark. Tahap ini bertujuan untuk meningkatkan kualitas data dengan menghapus data duplikat, menangani nilai kosong, serta melakukan standarisasi format pada beberapa

atribut seperti lokasi dan rentang gaji. Dataset hasil pembersihan kemudian disimpan ke dalam berkas `processed_jobs.csv` dan digunakan sebagai dasar pada tahap *feature engineering*.

	job_title	company_name	locat_	salary_	jo_	exp_	educati_	job_r_	poste_	source_platf
1	C++ Software En...	Surya Narayana In...	Kab. Bulele...	Tidak Ditamp...	Penuh W...	1-3 tahun	Minimal Sarj...	+2 C++	UrgentKemar...	glints
2	Software Engineer	PT. Meteor Inovas...	Kab. Tangerang...	Rp 7NBSPjt-9M	Kontrak	3-5 tahun	Minimal Sarj...	+5 Remote...	13 jam yang...	glints
3	Software Engineer	PT. MUAT LOGISTIK...	Jakarta Bar...	Rp 5NBSPjt-6M	Penuh W...	1-3 tahun	Minimal Sarj...	+4 Softwa...	10 jam yang...	glints
4	Software Engineer	Aldmic COOPN Digi...	Jakarta Bar...	Rp 7NBSPjt-10M	Penuh W...	3-5 tahun	Minimal Sarj...	JavaScript	12 jam yang...	glints
5	Software Engineer	BSG Group	Tangerang S...	Tidak Ditamp...	Penuh W...	1-3 tahun	Minimal Sarj...	+6 React...	3 hari yang...	glints
6	Software Engineer	PT Golden Tekstil...	Kab. Kendal...	Rp 3,2NBSPjt-	Penuh W...	1-3 tahun	Minimal Sarj...	SQL +12	8 hari yang...	glints
7	Software Engineer	PT Inter Sistem A...	Jakarta Sel...	Tidak Ditamp...	Penuh W...	1-3 tahun	Minimal Sarj...	+3 Laravel	14 hari yan...	glints
8	Software Engineer	PT Prima Vista So...	Jakarta Sel...	Tidak Ditamp...	Penuh W...	Not Spec...	Minimal Sarj...	Teamwork	17 hari yan...	glints
9	Software Engineer	Majoo Indonesia	Malang,Jawa...	Tidak Ditamp...	Penuh W...	1-3 tahun	Minimal Sarj...	+2 Softwa...	18 hari yan...	glints
10	Software Engineer	Dulwin Group	Bandung,Jaw...	Rp 4NBSPjt-5M	Penuh W...	1-3 tahun	Minimal Sarj...	+5 React...	12 jam yang...	glints
11	Software Engineer	Selaras Asia Mand...	Yogyakarta,...	Rp 5NBSPjt-10M	Penuh W...	3-5 tahun	Minimal Sarj...	+2 SQL	7 hari yang...	glints
12	Software Engineer	PT Teknologi Govi...	Jakarta Sel...	Rp 6,8NBSPjt-	Penuh W...	1-3 tahun	Minimal Sarj...	+6 Node.js	13 hari yan...	glints
13	Software Engine...	Pt. Solusi Pembay...	Tangerang,B...	Rp 10NBSPjt-1	Penuh W...	3-5 tahun	Minimal Dipl...	Hybrid +9	4 hari yang...	glints
14	Senior Software...	otaQku	Jakarta Sel...	Rp 8NBSPjt-12M	Penuh W...	3-5 tahun	Minimal Sarj...	Mentoring	8 hari yang...	glints
15	Software Engine...	PT Reka Multi Apt...	Jakarta Pus...	Rp 6NBSPjt-12M	Penuh W...	1-3 tahun	Minimal Sarj...	+16 SQL	9 hari yang...	glints
16	Software Engine...	Dulwin Group	Bandung,Jaw...	Rp 1,5NBSPjt-	Magang	1-3 tahun	Minimal Sarj...	PostgreSQL	10 jam yang...	glints
17	Senior Software...	Darmawan Aryansya...	Jakarta Sel...	Rp 13NBSPjt-1M	Penuh W...	5-10 tah...	Minimal Dipl...	+2 Go / G...	Kemarin	glints
18	Senior Software...	PT Teknologi Stru...	Jakarta Sel...	Rp 15NBSPjt-1M	Penuh W...	5-10 tah...	Minimal Sarj...	+2 Agile	2 hari yang...	glints
19	Junior Software...	PT Mitra Mandiri	Jakarta Sel...	Rp 6NBSPjt-7M	Penuh W...	1-3 tahun	Minimal Sarj...	+4 Java	3 hari yang...	glints
20	ROS Software En...	PT Widya Inovasi	Kab. Sleman...	Rp 4NBSPjt-5M	Penuh W...	1-3 tahun	Minimal Sarj...	+6 Ros So...	6 hari yang...	glints
21	Junior Software...	Hijrahfood Group	Bekasi,Jawa...	Rp 5NBSPjt-6M	Penuh W...	1-3 tahun	Minimal Dipl...	+3 GIT	14 hari yan...	glints
22	Software Engine...	Algobash	Jakarta Sel...	Rp 3NBSPjt-6M	Magang	Not Spec...	Minimal Sarj...	+4 TypeSc...	15 hari yan...	glints
23	Senior Software...	Quanta Data Ltd	Jakarta Pus...	Rp 4NBSPjt-1M	Penuh W...	3-5 tahun	Minimal Sarj...	+10 React...	20 hari yan...	glints

Selanjutnya dilakukan proses *feature selection* untuk menghasilkan dataset akhir yang lebih terstruktur dan siap digunakan dalam analisis eksploratif maupun proses *clustering*. Dataset hasil akhir disimpan dalam berkas `jobs_featured.csv` yang berisi atribut-atribut yang telah dibersihkan dan disesuaikan dengan kebutuhan penelitian. Proses ini bertujuan untuk meningkatkan kualitas data sehingga hasil analisis yang diperoleh menjadi lebih akurat dan mudah diinterpretasikan.

3.3 Analisis Data Menggunakan Apache Spark SQL

Setelah proses *data cleaning* dan *feature engineering* selesai dilakukan, tahap berikutnya adalah analisis data menggunakan Apache Spark SQL. Analisis ini dilakukan untuk memperoleh gambaran umum mengenai kondisi pasar kerja di Indonesia berdasarkan data lowongan kerja yang berhasil dikumpulkan dari platform Glints. Spark SQL digunakan karena mampu melakukan proses agregasi dan pengolahan data dalam jumlah besar secara efisien melalui pendekatan *distributed computing*.

3.3.1 Analisis Perusahaan dengan Jumlah Lowongan Terbanyak

```

PS C:\Users\User\PycharmProjects\ABD> python spark_jobs\spark_sql_analysis.py
Membuat sesi Apache Spark...
26/06/13 03:31:28 WARN Shell: Did not find winutils.exe: java.io.FileNotFoundException: java.io.FileNotFoundException: HADOOP_HOME and hadoop.home.dir are un
set. -see https://wiki.apache.org/hadoop/WindowsProblems
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
26/06/13 03:31:28 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Membaca dataset dari data\processed\jobs_featured.csv...
Temporary SQL View 'jobs' berhasil dibuat.

```

```

--- 1. TOP 10 PERUSAHAAN TERAKTIF ---
+-----+-----+
|company_name|jumlah_lowongan|
+-----+-----+
|PT Sigma Global Teknologi|37|
|Glints Taploker|9|
|PT. Barrans Global Mandiri|6|
|PT Tricada Intronik|6|
|Nusantara Sakti Group|6|
|PT Pronata Data Insani|4|
|PT Aktualisasi Gratia Talenta Indonesia|4|
|PT Pasti Makmur Abadi|4|
|Ruangguru|4|
|Duluin Group|3|
+-----+-----+

```

Berdasarkan hasil analisis, PT Sigma Global Teknologi menjadi perusahaan dengan jumlah lowongan terbanyak, yaitu sebanyak 37 lowongan. Posisi berikutnya ditempati oleh Glints Taploker dengan 9 lowongan, disusul beberapa perusahaan lain seperti PT Barrans Global Mandiri, PT Tricada Intronik, dan Nusantara Sakti Group. Hasil ini menunjukkan bahwa terdapat beberapa perusahaan yang secara aktif melakukan proses rekrutmen dalam periode pengambilan data. Dalam konteks analisis pasar kerja, informasi ini dapat digunakan untuk mengidentifikasi perusahaan yang memiliki kebutuhan tenaga kerja relatif tinggi dibandingkan perusahaan lainnya.

3.3.2 Analisis Kota dengan Jumlah Lowongan Terbanyak dan Jenis Pekerjaan

```

--- 2. TOP 10 KOTA PENEMPATAN TERBANYAK ---
+-----+-----+
|city|jumlah_lowongan|
+-----+-----+
|Jakarta Selatan|221|
|Jakarta Barat|118|
|Jakarta Pusat|79|
|Bandung|70|
|Jakarta Utara|68|
|Kab. Tangerang|55|
|Surabaya|54|
|Tangerang|50|
|Kab. Sleman|44|
|Jakarta Timur|35|
+-----+-----+

```

```

--- 3. JUMLAH PEKERJAAN BERDASARKAN TIPE PEKERJAAN ---
+-----+-----+
|job_type|jumlah_lowongan|
+-----+-----+
|Penuh Waktu|835|
|Kontrak|190|
|Magang|72|
|Freelance|25|
|Paruh Waktu|11|
+-----+-----+

```

Berdasarkan hasil analisis, kota dengan jumlah lowongan terbanyak adalah Jakarta Selatan dengan 221 lowongan, disusul Jakarta Barat sebanyak 118 lowongan dan Jakarta Pusat sebanyak 79 lowongan. Selain itu, Bandung dan Jakarta Utara juga termasuk wilayah dengan jumlah lowongan yang cukup tinggi. Hasil ini menunjukkan bahwa peluang kerja pada dataset lebih banyak terkonsentrasi di wilayah perkotaan besar, khususnya kawasan Jakarta dan sekitarnya.

Berdasarkan hasil pengelompokan jenis pekerjaan, kategori Penuh Waktu mendominasi dengan total 835 lowongan. Selanjutnya terdapat kategori Kontrak sebanyak 190 lowongan, Magang sebanyak 72 lowongan, *Freelance* sebanyak 25 lowongan, dan Paruh Waktu sebanyak 11 lowongan. Hasil ini menunjukkan bahwa mayoritas perusahaan lebih banyak membuka posisi kerja permanen dibandingkan jenis pekerjaan lainnya. Dari perspektif pasar tenaga kerja, kondisi ini mengindikasikan bahwa perusahaan masih lebih membutuhkan tenaga kerja dengan komitmen jangka panjang dibandingkan tenaga kerja sementara.

3.3.3 Analisis Rata-Rata Rentang Gaji dan Posisi Pekerjaan Paling Banyak Dicari

```
--- 4. RATA-RATA GAJI MINIMUM DAN MAKSIMUM (RUPIAH) ---
+-----+-----+
|rata_rata_gaji_min|rata_rata_gaji_max|
+-----+-----+
| 5193473.192307692| 7327622.377622378|
+-----+-----+

--- 5. 10 POSISI PEKERJAAN PALING BANYAK DICARI ---
+-----+-----+
|job_title|jumlah_posisi|
+-----+-----+
|Full Stack Developer|28|
|Business Analyst|23|
|Web Developer|22|
|DevOps Engineer|21|
|Data Analyst|21|
|Graphic Designer|20|
|IT Project Manager|17|
|Administrator HR|16|
|Digital Marketing|16|
|Data Engineer|16|
+-----+-----+

Menutup sesi Spark...
```

Hasil analisis menunjukkan bahwa rata-rata gaji minimum yang ditawarkan perusahaan berada pada kisaran Rp5.193.473 per bulan, sedangkan rata-rata gaji maksimum mencapai Rp7.327.622 per bulan. Perbedaan antara nilai minimum dan maksimum menunjukkan adanya variasi kompensasi yang ditawarkan oleh perusahaan sesuai dengan kebutuhan kompetensi, tingkat pengalaman, dan tanggung jawab pekerjaan. Informasi ini dapat digunakan untuk memberikan gambaran umum mengenai tingkat kompensasi yang berlaku pada pasar kerja Indonesia berdasarkan data yang berhasil dikumpulkan.

Hasil analisis menunjukkan bahwa posisi *Full Stack Developer* menjadi posisi yang paling banyak dicari dengan total 28 lowongan. Posisi lain yang juga memiliki permintaan tinggi antara lain *Business Analyst* (23 lowongan), *Web Developer* (22 lowongan), *DevOps Engineer* (21 lowongan), dan *Data Analyst* (21 lowongan). Temuan ini menunjukkan bahwa kebutuhan tenaga kerja pada bidang teknologi informasi masih mendominasi pasar kerja digital di Indonesia. Tingginya permintaan terhadap posisi-posisi tersebut juga mencerminkan meningkatnya kebutuhan perusahaan terhadap kemampuan pengembangan perangkat lunak, pengelolaan infrastruktur digital, serta pengolahan data untuk mendukung proses bisnis.

3.4 Clustering Lowongan Kerja Menggunakan Apache Spark MLlib

Proses *clustering* dilakukan menggunakan algoritma *K-Means* yang tersedia pada Apache Spark MLlib untuk mengelompokkan lowongan pekerjaan berdasarkan kemiripan

judul pekerjaan (*job title*). Sebelum proses *clustering*, dilakukan tahapan *text preprocessing* berupa konversi huruf menjadi *lowercase*, penghapusan karakter non-huruf menggunakan *regular expression*, pemisahan kata (*tokenization*), penghapusan *stopwords*, serta transformasi teks menjadi representasi numerik menggunakan metode *HashingTF* dan *Inverse Document Frequency (IDF)*. Tahapan ini bertujuan agar data teks dapat diproses oleh algoritma *machine learning*. Setelah proses transformasi selesai, dilakukan pengujian beberapa nilai *k* (jumlah cluster) yaitu 3, 4, 5, dan 6 untuk menentukan model terbaik berdasarkan nilai *Silhouette Score*.

```
Problems Output Debug Console Terminal Ports
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
26/06/13 03:40:08 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Membaca dataset dari data\processed\jobs_featured.csv...
Data valid untuk diproses ML: 1133 baris.
Kolom fitur: job_title (setelah normalisasi teks)

=====
EKSPERIMEN NILAI K
=====

[Melatih K-Means dengan k=3]
26/06/13 03:40:13 WARN StopWordsRemover: Default locale set was [en_ID]; however, it was not found in available locales in JVM, falling back to en_US locale. Set param 'locale' in order to respect another locale.
26/06/13 03:40:16 WARN InstanceBuilder: Failed to load implementation from:dev.ludovic.netlib blas.JNIBLAS
Silhouette Score : 0.0351 [OK]
Distribusi Cluster:
Cluster 0: 947 lowongan
Cluster 1: 63 lowongan
Cluster 2: 123 lowongan

[Melatih K-Means dengan k=4]
26/06/13 03:40:17 WARN StopWordsRemover: Default locale set was [en_ID]; however, it was not found in available locales in JVM, falling back to en_US locale. Set param 'locale' in order to respect another locale.
26/06/13 03:40:18 WARN InstanceBuilder: Failed to load implementation from:dev.ludovic.netlib blas.JNIBLAS
Silhouette Score : 0.0245 [OK]
Distribusi Cluster:
Cluster 0: 888 lowongan
Cluster 1: 63 lowongan
Cluster 2: 115 lowongan
Cluster 3: 75 lowongan

[Melatih K-Means dengan k=5]
26/06/13 03:40:18 WARN StopWordsRemover: Default locale set was [en_ID]; however, it was not found in available locales in JVM, falling back to en_US locale. Set param 'locale' in order to respect another locale.
Silhouette Score : -0.0273 [!] ada cluster < 10 anggota
Distribusi Cluster:
Cluster 0: 905 lowongan
Cluster 1: 60 lowongan
Cluster 2: 3 lowongan
Cluster 3: 76 lowongan
Cluster 4: 89 lowongan

[Melatih K-Means dengan k=6]
26/06/13 03:40:19 WARN StopWordsRemover: Default locale set was [en_ID]; however, it was not found in available locales in JVM, falling back to en_US locale. Set param 'locale' in order to respect another locale.
Silhouette Score : -0.0599 [!] ada cluster < 10 anggota
Distribusi Cluster:
Cluster 0: 33 lowongan
Cluster 1: 1026 lowongan
Cluster 2: 33 lowongan
Cluster 3: 8 lowongan
Cluster 4: 30 lowongan
Cluster 5: 3 lowongan
```

Berdasarkan hasil pengujian, model dengan nilai $k = 3$ menghasilkan *Silhouette Score* tertinggi sebesar 0,0351 dan seluruh *cluster* memenuhi batas minimum jumlah anggota yang telah ditentukan. Sementara itu, model dengan $k = 5$ dan $k = 6$ menghasilkan beberapa cluster yang berisi kurang dari 10 data sehingga dianggap kurang representatif. Oleh karena itu, model *K-Means* dengan tiga cluster dipilih sebagai model terbaik. Proses pemilihan model ini sesuai dengan konsep evaluasi pada *unsupervised learning*, yaitu memilih konfigurasi *cluster* yang memiliki tingkat kemiripan internal tinggi dan perbedaan antarcluster yang cukup jelas.

```

=====
RINGKASAN SEMUA NILAI K
=====
  k    Silhouette Score    Valid?
-----
  3         0.0351         YA
  4         0.0245         YA
  5        -0.0273        TIDAK
  6        -0.0599        TIDAK

>>> MODEL TERBAIK (distribusi valid): k=3 | Silhouette Score = 0.0351

=====
ANALISIS DETAIL MODEL TERBAIK (k=3)
=====

--- Distribusi Cluster ---
+-----+-----+
|cluster_prediction|count|
+-----+-----+
|0                 |947 |
|1                 |63  |
|2                 |123 |
+-----+-----+

```

Hasil *clustering* menunjukkan bahwa *Cluster 0* berisi 947 lowongan dan didominasi oleh posisi seperti *Full Stack Developer*, *Business Analyst*, *Web Developer*, *Data Analyst*, serta *Graphic Designer*. *Cluster 1* berisi 63 lowongan yang didominasi oleh posisi *DevOps Engineer*, *Software Engineer Intern*, dan *UI/UX Designer Intern*. Sementara itu, *Cluster 2* berisi 123 lowongan yang banyak berkaitan dengan bidang keuangan dan administrasi seperti *Finance Accounting & Tax*, *Human Resources*, serta *Sales*. Hasil tersebut menunjukkan bahwa algoritma *K-Means* mampu mengelompokkan lowongan kerja berdasarkan kemiripan kata-kata yang terkandung pada judul pekerjaan tanpa memerlukan label sebelumnya.

--- Interpretasi dan Contoh Data Per Cluster ---

=====

CLUSTER 0 (947 lowongan)

=====

Top 5 Judul Pekerjaan Dominan:

- Full Stack Developer (28 lowongan)
- Business Analyst (23 lowongan)
- Web Developer (22 lowongan)
- Data Analyst (21 lowongan)
- Graphic Designer (20 lowongan)

Contoh 10 Data dari Cluster 0:

job_title	company_name	location
Software Engineer	PT. Meteor Inovasi Digital	Kab. Tangerang,Banten
Software Engineer	PT. MUAT LOGISTIK INDONESIA	Jakarta Barat,DKI Jakarta
Software Engineer	Aldmic COOPN Digital	Jakarta Barat,DKI Jakarta
Software Engineer	BSG Group	Tangerang Selatan,Banten
Software Engineer	PT Golden Tekstil Indonesia	Kab. Kendal,Jawa Tengah
Software Engineer	PT Inter Sistem Asia	Jakarta Selatan,DKI Jakarta
Software Engineer	PT Prima Vista Solusi	Jakarta Selatan,DKI Jakarta
Software Engineer	Majoo Indonesia	Malang,Jawa Timur
Software Engineer	Duluin Group	Bandung,Jawa Barat
Software Engineer	Selaras Asia Mandiri	Yogyakarta,DI Yogyakarta

=====

CLUSTER 1 (63 lowongan)

=====

Top 5 Judul Pekerjaan Dominan:

- DevOps Engineer (21 lowongan)
- Software Engineer Intern (3 lowongan)
- UI/UX Designer Intern (3 lowongan)
- Affiliate Marketing Intern (1 lowongan)
- Junior DevOps Engineer (1 lowongan)

Contoh 10 Data dari Cluster 1:

job_title	company_name	location
Software Engineer (Golang Engineer)	Pt. Solusi Pembayaran Elektronik	Tangerang,Banten
Software Engineer Intern	Duluin Group	Bandung,Jawa Barat
Software Engineer Intern	Imperial Healthtech	Semarang,Jawa Tengah
Software Engineer (IT Operational Engineer)	Pt. Solusi Pembayaran Elektronik	Tangerang,Banten
Software Engineer Intern	Studia Academy Ltd	Jakarta Barat,DKI Jakarta
Software Developer Intern/Staff - Jakarta	PT. Norxel Teknologi Indonesia	Jakarta Utara,DKI Jakarta
[[INTERN]] Backend Developer	Meda	Surabaya,Jawa Timur
DevOps Engineer	PT Tricada Intronic	Bandung,Jawa Barat
DevOps Engineer	Altek Citra Cemerlang	Jakarta Pusat,DKI Jakarta
DevOps Engineer	GlobalXtreme	Kab. Badung,Bali

=====

CLUSTER 2 (123 lowongan)

=====

Top 5 Judul Pekerjaan Dominan:

- Finance Accounting & Tax (5 lowongan)
- Manager Finance, Accounting & Tax (4 lowongan)
- Human Resources (HR) Coordinator (3 lowongan)
- Sales Taking Order (Sales TO) (3 lowongan)
- Finance, Accounting & Tax (3 lowongan)

Contoh 10 Data dari Cluster 2:

job_title	company_name	location
C++ Software Engineer	Surya Narayana Indonesia	Kab. Buleleng,Bali
Backend Developer (.NET)	PT Sigma Global Teknologi	Jakarta Selatan,DKI Jakarta
Backend Developer - Internship	Peduly	Surabaya,Jawa Timur
Backend Developer - Internship	Rintisari	Surabaya,Jawa Timur
Frontend Developer - Internship	Peduly	Surabaya,Jawa Timur
- Sales Taking Order (Sales TO) (3 lowongan)		
- Finance, Accounting & Tax (3 lowongan)		

Contoh 10 Data dari Cluster 2:

job_title	company_name	location
C++ Software Engineer	Surya Narayana Indonesia	Kab. Buleleng,Bali
Backend Developer (.NET)	PT Sigma Global Teknologi	Jakarta Selatan,DKI Jakarta
Backend Developer - Internship	Peduly	Surabaya,Jawa Timur
Backend Developer - Internship	Rintisari	Surabaya,Jawa Timur
Frontend Developer - Internship	Peduly	Surabaya,Jawa Timur
Frontend Developer (Reactjs, Nuxtjs)	PT Sigma Global Teknologi	Jakarta Selatan,DKI Jakarta


Model akhir yang digunakan adalah *K-Means* dengan jumlah cluster sebanyak tiga dan *Silhouette Score* sebesar 0,0351. Dataset yang digunakan terdiri atas 1.133 data lowongan pekerjaan dengan atribut utama berupa judul pekerjaan. Meskipun nilai *Silhouette Score* tergolong rendah, hasil pengelompokan masih mampu menunjukkan pola umum pasar kerja dan menghasilkan segmentasi posisi pekerjaan yang cukup berbeda. Hal ini

menunjukkan bahwa Apache Spark MLlib dapat dimanfaatkan untuk melakukan analisis *unsupervised learning* pada data lowongan kerja serta memberikan gambaran mengenai kelompok pekerjaan yang memiliki karakteristik serupa berdasarkan informasi tekstual pada judul pekerjaan.


```
=== INFORMASI MODEL TERBAIK ===
Algoritma      : K-Means (Spark MLlib)
Jumlah Cluster : 3
Silhouette Score : 0.0351
Jumlah Data    : 1133 baris
Kolom Fitur    : job_title
Preprocessing  : lower + regexp_replace + StopWordsRemover + HashingTF(1024) + IDF(minDocFreq=3)

Menutup sesi Spark...
PS C:\Users\User\PycharmProjects\ABD> SUCCESS: The process with PID 13032 (child process of PID 41020) has been terminated.
SUCCESS: The process with PID 41020 (child process of PID 32132) has been terminated.
SUCCESS: The process with PID 32132 (child process of PID 38364) has been terminated.
[]
```


3.5 Visualisasi



Berdasarkan gambar tersebut, Jakarta Selatan menempati posisi pertama dengan jumlah lowongan mencapai 221 posisi, diikuti Jakarta Barat sebanyak 118 posisi dan Jakarta Pusat sebanyak 79 posisi. Selain wilayah DKI Jakarta, kota-kota besar seperti Bandung, Surabaya, dan Tangerang juga memiliki jumlah lowongan yang cukup tinggi. Hasil ini menunjukkan bahwa peluang kerja masih terkonsentrasi pada kawasan metropolitan dan pusat ekonomi nasional. Temuan tersebut sejalan dengan kondisi industri digital dan bisnis modern yang umumnya beroperasi di kota-kota besar sehingga membutuhkan tenaga kerja dalam jumlah yang lebih banyak dibandingkan daerah lainnya.



Hasil visualisasi menunjukkan bahwa jenis pekerjaan penuh waktu (*full time*) mendominasi secara signifikan dengan jumlah lebih dari 800 lowongan. Di posisi berikutnya terdapat pekerjaan kontrak sebanyak sekitar 190 lowongan dan program magang sebanyak 72 lowongan. Sementara itu, pekerjaan *freelance* dan paruh waktu (*part time*) memiliki jumlah yang relatif sedikit. Kondisi ini mengindikasikan bahwa mayoritas perusahaan lebih memilih merekrut karyawan tetap untuk memenuhi kebutuhan operasional dan pengembangan bisnis jangka panjang dibandingkan model kerja yang bersifat sementara.



Berdasarkan hasil yang diperoleh, Cluster 0 berisi 947 lowongan, Cluster 1 berisi 63 lowongan, dan Cluster 2 berisi 123 lowongan. Dominasi jumlah data pada Cluster 0 menunjukkan bahwa sebagian besar posisi pekerjaan memiliki karakteristik yang relatif serupa berdasarkan kemiripan kata pada judul pekerjaan. Sementara itu, Cluster 1 dan Cluster 2 merepresentasikan kelompok pekerjaan yang lebih spesifik dan memiliki pola yang berbeda dari kelompok utama. Hasil ini membuktikan bahwa metode *unsupervised learning* menggunakan algoritma *K-Means* mampu mengidentifikasi pola dan segmentasi pekerjaan secara otomatis tanpa memerlukan label kategori sebelumnya, sehingga dapat digunakan untuk membantu memahami struktur pasar kerja berdasarkan kemiripan jenis posisi yang tersedia.

BAB IV Penutup

Proyek analisis lowongan kerja ini berhasil mengimplementasikan tahapan *big data analytics* mulai dari pengumpulan data melalui teknik *web scraping*, pembersihan dan persiapan data, analisis menggunakan Apache Spark SQL, hingga pengelompokan data menggunakan algoritma *K-Means* pada Spark MLlib. Berdasarkan hasil analisis, diperoleh berbagai informasi penting mengenai kondisi pasar kerja di Indonesia, seperti kota dengan jumlah lowongan terbanyak, dominasi jenis pekerjaan penuh waktu, rata-rata rentang gaji yang ditawarkan perusahaan, serta pola pengelompokan posisi pekerjaan berdasarkan kemiripan judul lowongan. Seluruh proses menunjukkan bahwa pemanfaatan teknologi *big data* mampu membantu mengolah dan mengekstraksi informasi bernilai dari data lowongan kerja yang jumlahnya relatif besar dan beragam.

Jika dikaitkan dengan karakteristik 5V pada *Big Data*, proyek ini telah memenuhi aspek *Volume* melalui pengolahan lebih dari seribu data lowongan kerja, *Variety* melalui keberagaman atribut seperti lokasi, gaji, pendidikan, pengalaman, dan deskripsi pekerjaan, serta *Value* melalui informasi dan wawasan yang dihasilkan dari proses analisis. Aspek *Velocity* telah terpenuhi secara terbatas karena proses pengumpulan data dilakukan secara otomatis namun belum berjalan secara *real-time*. Sementara itu, aspek *Veracity* masih memiliki ruang untuk ditingkatkan karena kualitas data sangat bergantung pada konsistensi informasi yang ditampilkan oleh platform sumber. Pada pengembangan selanjutnya, penelitian ini dapat diperluas dengan menambahkan sumber data dari lebih banyak platform rekrutmen, menerapkan proses pembaruan data secara berkala, serta memanfaatkan metode *machine learning* yang lebih kompleks untuk menghasilkan analisis pasar kerja yang lebih akurat dan komprehensif.